



Universität  
Zürich<sup>UZH</sup>

Institut für Informatik

# Informatik und Wirtschaft Künstliche Intelligenz



## Wichtiger Hinweis: Diese Vorlesung wird live in einen zweiten Hörsaal "gestreamt" sowie aufgezeichnet und als Podcast via OLAT verteilt

- **Falls Sie verhindern wollen, dass Sie in Podcast erscheinen, setzen Sie sich bitte in die hinteren Reihen oder verfolgen Sie die Vorlesung im Übertragungssaal** (siehe auch verlinktes Merkblatt sowie [www.tiny.uzh.ch/158](http://www.tiny.uzh.ch/158) ).
- **Es kann vorkommen, dass einzelne als Podcasts vorgesehene Veranstaltungen z.B. aufgrund technischer Störungen nicht oder nicht störungsfrei aufgezeichnet und daher nicht oder nur teilweise zur Verfügung gestellt werden können.** Auch kann die ständige Verfügbarkeit der Podcasts u.a. aus technischen Gründen nicht garantiert werden. Studierende können sich daher nicht darauf verlassen, dass ihnen eine Veranstaltung in jedem Fall und zeitlich unbeschränkt als Podcast zur Verfügung steht. Der Verzicht von Studierenden auf den Besuch von Veranstaltungen und auf das Erstellen eigener Notizen erfolgt demnach auf eigenes Risiko.
- Bei **inhaltlichen Widersprüchen haben Skripte oder anderes als prüfungsrelevant deklariertes Material Vorrang vor den Podcasts.**
- Die Aufnahmen dürfen **nur für den Privatgebrauch verwendet werden.** Eine **Weiterverbreitung in welcher Form auch immer, ganz oder in Auszügen, ist nicht erlaubt und kann disziplinarisch und anderweitig geahndet werden.**
- Siehe gesamte, rechtlich relevante Information unter:  
[https://www.zi.uzh.ch/dam/jcr:3d10d79d-6b18-40e0-a824-a9d3a581e7a2/Podcast\\_Merkblatt\\_Studierende.pdf](https://www.zi.uzh.ch/dam/jcr:3d10d79d-6b18-40e0-a824-a9d3a581e7a2/Podcast_Merkblatt_Studierende.pdf)

**Sie können via Kilcker aktiv mitmachen...**



## Digitale Güter II

- Fragen/Hinweise
- Künstliche Intelligenz



## Digitale Güter II

- Fragen/Hinweise
- Künstliche Intelligenz



Universität  
Zürich <sup>UZH</sup>

Digital Society Initiative

# Artificial Intelligence The Good, the Bad, and the Challenges

Abraham Bernstein





www.nytimes.com/spotlight/artifi

ARTIFICIAL INTELLIGENCE The New York Times Account

TECHNOLOGY

## Artificial Intelligence

IMAGES GENERATED BY A.I.

BEN MYHRE

CRITIC'S NOTEBOOK

### How A.I. Is Remodeling the Fantasy Home

Amid an intractable real estate crisis, fake luxury houses offer a delusion of one's own.

22h ago · By AMANDA HESS

Generative A.I.'s Biggest Impact Will Be in Banking and Tech, Report Says

For some companies, the new technology is an opportunity to enhance productivity and profit. Will their workers benefit as well?

February 1, 2024 · By STEVE LOHR

Amazon Enters Chatbot Fray With Shopping Tool

The tech giant introduced the Rufus chatbot. It has lagged behind others on introducing consumer-facing generative artificial intelligence.

11h ago · By KAREN WEISE

THE SHIFT

### Can This A.I.-Powered Search Engine Replace Google? It Has for Me.

A start-up called Perplexity shows what's possible for a search engine built from scratch with artificial intelligence.

February 1, 2024 · By KEVIN ROOSE

Nvidia's Big Tech Rivals Put Their Own A.I. Chips on the Table


George Carlin's Estate Sues Podcasters Over A.I. Episode

Explicit Deepfake Images of Taylor Swift Elude Safeguards and Swamp Social Media

Mediapocalypse Now, a16z's Chris Dixon Defends Crypto, and HatGPT

We Asked A.I. to Create the Joker. It Generated a Copyrighted Image.

https://www.nytimes.com/2024/02/04/arts/design/artificial-intelligence-fantasy-home.html










Convoy ABC will be  
attacked today at  
five pm



AHPFPE OZE  
MKKI HW  
BHMGWPSZ  
USQNK TL YEMY  
WU







Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative



## Turing Test





Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative



## Turing Test




|                      | Act like a human                                   | Act rationally                  |
|----------------------|----------------------------------------------------|---------------------------------|
| Human-like reasoning | How do humans act?                                 | Can humans be rational?         |
| Any-style reasoning  | <i>Turing Test</i><br>Can I simulate human action? | Can I build a rational machine? |






# Deduction



# Induction



# Analogy






# Inductive Reasoning







| Passenger | class | age   | sex    | survived |
|-----------|-------|-------|--------|----------|
| 1         | 1st   | adult | male   | yes      |
| 2         | 1st   | adult | male   | yes      |
| 3         | 1st   | adult | male   | yes      |
| 4         | 1st   | adult | male   | yes      |
| 5         | 1st   | adult | male   | yes      |
| ...       | ...   | ...   | ...    | ...      |
| 2194      | crew  | adult | female | yes      |
| 2195      | crew  | adult | female | yes      |
| 2196      | crew  | adult | female | yes      |
| 2197      | crew  | adult | female | yes      |
| 2198      | crew  | adult | female | yes      |
| 2199      | crew  | adult | female | no       |
| 2200      | crew  | adult | female | no       |
| 2201      | crew  | adult | female | no       |








Universität  
Zürich<sup>UZH</sup>


Digital Society Initiative

Data is interesting...





## Split Data Based on Interestingness: Decision Trees








Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative



Correct?



# Question #1

How correct does AI need to be?



Patients who got this treatment also had the following treatments ...





## Use probability Theory: Bayes' Rule



Thomas Bayes 1702-1761



$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

$P(\text{Bird} \mid \text{Picture})$






## Get Inspired by Nature: Neural Networks




$$y_i = \omega_0 + \omega_1 x_{1,i} + \dots + \omega_n x_{n,i} + \epsilon_i$$








## Get Inspired by Nature: Neural Networks





## Large Language Models etc.



$$P(\text{"ranking"} | \text{"uzh mba"}) = \frac{P(\text{"mba uzh ranking"})}{P(\text{"mba uzh"})}$$

$$\approx \frac{\text{count}(\text{"mba uzh ranking"})}{\text{count}(\text{"mba uzh"})}$$

### A fixed-window neural Language Model

output distribution

$$\hat{y} = \text{softmax}(Uh + b_2) \in \mathbb{R}^{|V|}$$

hidden layer

$$h = f(We + b_1)$$


concatenated word embeddings

$$e = [e^{(1)}; e^{(2)}; e^{(3)}; e^{(4)}]$$

words / one-hot vectors

$$x^{(1)}, x^{(2)}, x^{(3)}, x^{(4)}$$

20





## Large Language Models 1999 — Parlamentspeak (GPT-2 with transfer learning)

**Prompt:** Bündnerfleisch ist

Bündnerfleisch ist eine wichtige Stütze, um die Landwirtschaft zu stützen und um die Landwirtschaft zu stützen. Der Bundesrat hat im Hinblick auf eine mögliche Änderung in der Landwirtschaftspolitik ein Moratorium geprüft. Es wurde dann eine entsprechende Verordnung erarbeitet. Die Kommission hat sich dann dem Nationalrat angeschlossen. Ich möchte hier noch eine Präzisierung einbringen. Der Nationalrat hat eine Bestimmung geschaffen, in der er die Auswirkungen auf die Tiere und ihre Nutztiere und auch auf deren Auswirkungen auf die Art der Nahrungsmittel geregelt. Diese Präzisierung ist nötig, weil der Bund mit dieser Regelung die Auswirkungen der Massnahme gemäss WTO-Abkommen regeln will. Das Bundesamt und auch die Kantone haben in dieser Verordnung entsprechende Regelungen geschaffen. In diesem Sinne möchte ich noch einmal darauf hinweisen, dass der Nationalrat diese Ergänzung noch einmal aufnehmen und ergänzen wird." "Es ist schon eine interessante Frage. Es ist nicht so, dass ich Ihnen nur sagen möchte, dass die Frage der Nutztierhaltung nicht geklärt worden ist.





## ChatGPT 2023

**Prompt:** "bitte **schreibe** eine politische Rede zum Thema Bündnerfleisch"

Meine verehrten Mitbürgerinnen und Mitbürger,

ich stehe heute vor Ihnen, um über ein Thema zu sprechen, das nicht nur die Herzen der Menschen im Herzen Europas berührt, sondern auch eine große Bedeutung für unsere Identität und Kultur hat - das Bündnerfleisch.

Das Bündnerfleisch, dieses wunderbare und traditionsreiche Produkt, ist nicht nur ein einfaches Lebensmittel, sondern verkörpert eine lange Geschichte von Handwerkskunst, Stolz und nachhaltiger Landwirtschaft. Es ist ein wahrer Schatz, der unsere Region Graubünden auf der internationalen kulinarischen Karte repräsentiert.

Wenn wir an Bündnerfleisch denken, denken wir an die malerischen Berglandschaften, die saftigen Almwiesen und die frische Bergluft, die die Grundlage für die Aufzucht des Viehs bilden. Es ist ein Beweis für die Verbindung zwischen Mensch und Natur, für die Achtsamkeit gegenüber unserer Umwelt und für den Respekt vor unseren Wurzeln.

Bündnerfleisch ist auch ein Symbol für die hohe Qualität und das meisterhafte Handwerk, das in seiner Herstellung steckt. Es ist das Ergebnis jahrhundertealter Traditionen, die von Generation zu Generation weitergegeben wurden. Unsere Bündner Metzger und Bauern haben ihr ganzes Leben damit verbracht, diese Kunst zu perfektionieren und die besten Produkte anzubieten. Sie verdienen unsere Anerkennung und Unterstützung.



## ChatGPT 2023 — continued

...

Doch in einer Zeit des globalen Wandels und der Herausforderungen müssen wir uns fragen, wie wir unsere Traditionen bewahren und gleichzeitig an die Zukunft denken können. Wir müssen uns der Nachhaltigkeit verschreiben und sicherstellen, dass unsere landwirtschaftlichen Praktiken umweltverträglich sind. Wir müssen auch die Innovation fördern und neue Wege finden, um unsere Produkte auf den internationalen Märkten zu präsentieren.

Meine Damen und Herren, das Bündnerfleisch hat das Potenzial, ein Botschafter für unsere Region zu sein. Es kann uns helfen, den Tourismus anzukurbeln und die Wirtschaft zu stärken. Aber wir müssen auch sicherstellen, dass es für jeden zugänglich ist. Wir müssen die Preise erschwinglich halten und den Menschen die Möglichkeit geben, dieses kulturelle Erbe zu genießen.

Wir sollten stolz sein auf das, was wir erreicht haben, und unsere einzigartige Identität bewahren. Lasst uns gemeinsam dafür kämpfen, dass das Bündnerfleisch weiterhin auf unseren Tischen und in den Speisekarten der besten Restaurants weltweit zu finden ist. Lasst uns die Traditionen ehren, die Umwelt schützen und unsere Gemeinschaft stärken.


In diesem Sinne rufe ich Sie alle auf, das Bündnerfleisch zu unterstützen, es zu genießen und es mit Stolz zu teilen. Lassen Sie uns zusammenarbeiten, um unsere Region zu fördern und unsere Werte hochzuhalten.

Vielen Dank.



## Transparency?

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$



### Node 1 (Sigmoid)

```
class = 1st: 1.690
class = 2nd: 2.374
class = 3rd: -0.947
class = crew: 1.125
age = adult: -2.100
age = child: 2.109
sex = male: 0.518
sex = female: -0.534
Bias: -2.113
```

### Node 2 (Sigmoid)

```
class = 1st: 2.339
class = 2nd: 1.930
class = 3rd: 0.574
class = crew: -0.088
age = adult: 0.702
age = child: -0.736
sex = male: 1.361
sex = female: -1.336
Bias: -2.412
```

### Node 3 (Sigmoid)

```
class = 1st: -2.793
class = 2nd: -3.056
class = 3rd: 5.963
class = crew: -1.880
age = adult: 1.930
age = child: -1.902
sex = male: 2.504
sex = female: -2.546
Bias: 0.811
```

### Node 4 (Sigmoid)

```
class = 1st: 1.040
class = 2nd: 1.941
class = 3rd: 4.920
class = crew: 0.309
age = adult: 0.796
age = child: -0.820
sex = male: 2.422
sex = female: -2.413
Bias: -4.122
```

### Node 5 (Sigmoid)

```
class = 1st: -1.015
class = 2nd: 3.839
class = 3rd: -1.629
class = crew: 3.143
age = adult: 1.828
age = child: -1.782
sex = male: -0.188
sex = female: 0.189
Bias: -2.219
```

### Node 6 (Sigmoid)

```
class = 1st: 0.845
class = 2nd: 3.572
class = 3rd: -0.611
class = crew: -0.521
age = adult: -0.322
age = child: 0.312
sex = male: 0.540
sex = female: -0.610
Bias: -1.616
```

Output  
=====

### Class 'yes' (Sigmoid)

```
Node 1: 2.034
Node 2: -0.605
Node 3: -3.760
Node 4: -1.499
Node 5: -1.194
Node 6: -0.555
Threshold: 3.439
```

### Class 'no' (Sigmoid)

```
Node 1: -2.034
Node 2: 0.605
Node 3: 3.760
Node 4: 1.499
Node 5: 1.194
Node 6: 0.555
Threshold: -3.439
```





## What is an interpretable model? (Guidotti et al., 2018)

- “To interpret means **to give or provide the meaning or to explain and present in understandable terms some concepts**.  
Therefore, in data mining and machine learning, **interpretability is defined as the ability to explain or to provide the meaning in understandable terms to a human.**”
- **An explanation is an “interface” between the human and the algorithm.**
- Issues to consider
  - **Global vs. local interpretability** — Algorithm logic or only one case
  - **Time limitation** — The user has limited time
  - **Expertise** of user may differ
  - Black Box or White Box?

# Question #2

How transparent and understandable do decisions need to be??



Die Bundesversammlung – Das Schweizer Parlament  
Curia Vista – Die Geschäftsdatenbank

19.498 Parlamentarische Initiative

## Öffentliche und transparente Abstimmungen im Ständerat

Eingereicht von:

Minder Thomas  
Fraktion der Schweizerischen Volkspartei  
parteilos



Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative



## Bias?



Thomas Dewey

Harry S Truman





Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative



## More Bias?

**Science** AAAS

**Home** **News** **Journals** **Topics** **Careers**

Science Science Advances Science Immunology Science Robotics Science Signaling Science Translational Medicine

**SHARE** **REPORT**

0  
  
 0

**Semantics derived automatically from language corpora contain human-like biases**

Aylin Caliskan<sup>1,\*</sup>, Joanna J. Bryson<sup>1,2,\*</sup>, Arvind Narayanan<sup>1,\*</sup>  
+ See all authors and affiliations

*Science* 14 Apr 2017:  
Vol. 356, Issue 6334, pp. 183-186  
DOI: 10.1126/science.aal4230

**PRE** Peer Reviewed  
← see details



Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative

## More Bias?



Science 14 Apr 2017.  
Vol. 356, Issue 6334, pp. 183-186  
DOI: 10.1126/science.aal4230



Automatically from language corpora  
ases

Marayanan<sup>1,\*</sup>




Peer Reviewed  
← see details



## More Bias?

Percentage of the 54 skin lesion datasets that provide metadata for gender, age, ethnicity, and skin type






## Question #3

What kind of bias is acceptable?





# Deductive Reasoning







## Reasoning with Knowledge









Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative



## The Web as Knowledge Base: The Linked Open Data Cloud



<http://richard.cyganiak.de/2007/10/lod/>



# The Linked Open Data Cloud: Fake News?

The image illustrates the 'Linked Open Data Cloud' and its potential for spreading fake news. It features a background network of interconnected data nodes, a smartphone displaying a Wikipedia page for Johann Schneider-Ammann, and a Wikidata page for Bulgaria's anthem. A blue line connects the smartphone to the Wikidata page, highlighting the link between the two. A red box on the Wikidata page highlights the 'Despacito' entry under the 'Property / anthem' section, which is a clear example of a fake or incorrect entry in a linked data system.

**Wikidata Page: Difference between revisions of "Bulgaria (Q219)"**

Revision as of 15:33, 21 September 2017  
78.83.94.41 (talk)  
(Changed claim: anthem (P85): Despacito (Q28572509))  
(Tag: new editor changing statement)  
← Older edit

Revision as of 00:10, 5 October 2017  
Chetankale1978 (talk | contribs)  
(Changed claim: population (P1082): 7,101,859)  
Newer edit →

(5 intermediate revisions by 4 users not shown)

**Property / anthem**  
- Despacito

**Property / anthem**  
+ Mila Rodino

**Property / population**  
7,101,859  
+ Amount 7,101,859  
Unit 1

**Property / population: 7,101,859 / rank**  
+ Normal rank

**Property / population: 7,101,859 /**

<https://www.cnet.com/news/icymi-the-national-anthem-of-bulgaria-is-despacito/>

## Question #4

Who is accountable for mistakes?





# Analogical Reasoning








Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative

## Watching TV ...



# Privacy?



## How can we ensure privacy?

- **K-Anonymity**


A release of data is said to have the k-anonymity property if the information for each person contained in the release cannot be distinguished from at least k other people

- **L-Diversity**

An equivalence class is said to have l-diversity if there are at least l “well-represented” values for the sensitive attribute. A table is said to have l-diversity if every equivalence class of the table has l-diversity

- **Differential Privacy**

It is statistically impossible to differentiate between a result with any person in the dataset from a result without that person in the dataset (Dwork et al 2006)







## Differential Privacy: Using noise (i.e., reducing quality) to protect privacy



$$\frac{Pr[Q(D) \in S]}{Pr[Q(D') \in S]} \leq e^\epsilon$$

(Dwork et al 2006)

Definitions:

- $D$  is a database
- $D'$  is equal to  $D$  with the exception of one datapoint (person)
- $Q(D)$  is the answer to query  $Q$  on database  $D$
- $Q'(D)$  is the answer to query  $Q$  on database  $D'$
- $S$  set of possible answers
- $\epsilon$  regulates the amount of noise added



Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative




## Differential Privacy: Using noise (i.e., reducing quality) to protect privacy



$$\frac{\Pr[Q(D) \in S]}{\Pr[Q(D') \in S]} \leq e^\epsilon$$


(Dwork et al 2006)



(Dell'Aglio & Bernstein 2020)



## Differential Privacy: Using noise (i.e., reducing quality) to protect privacy




(Dell’Aglia & Bernstein 2020)




# Question #5

How do we trade-off between  
Privacy and Quality?





## How do I reason with analogies?








## We live in a globalized world...

### The Moral Machine experiment

Edmond Awad<sup>1</sup>, Sohan Dsouza<sup>1</sup>, Richard Kim<sup>1</sup>, Jonathan Schulz<sup>2</sup>, Joseph Henrich<sup>2</sup>, Azim Shariff<sup>3\*</sup>, Jean-François Bonnefon<sup>4\*</sup> & Iyad Rahwan<sup>1,5\*</sup>

NATURE | VOL 563 | 1 NOVEMBER 2018





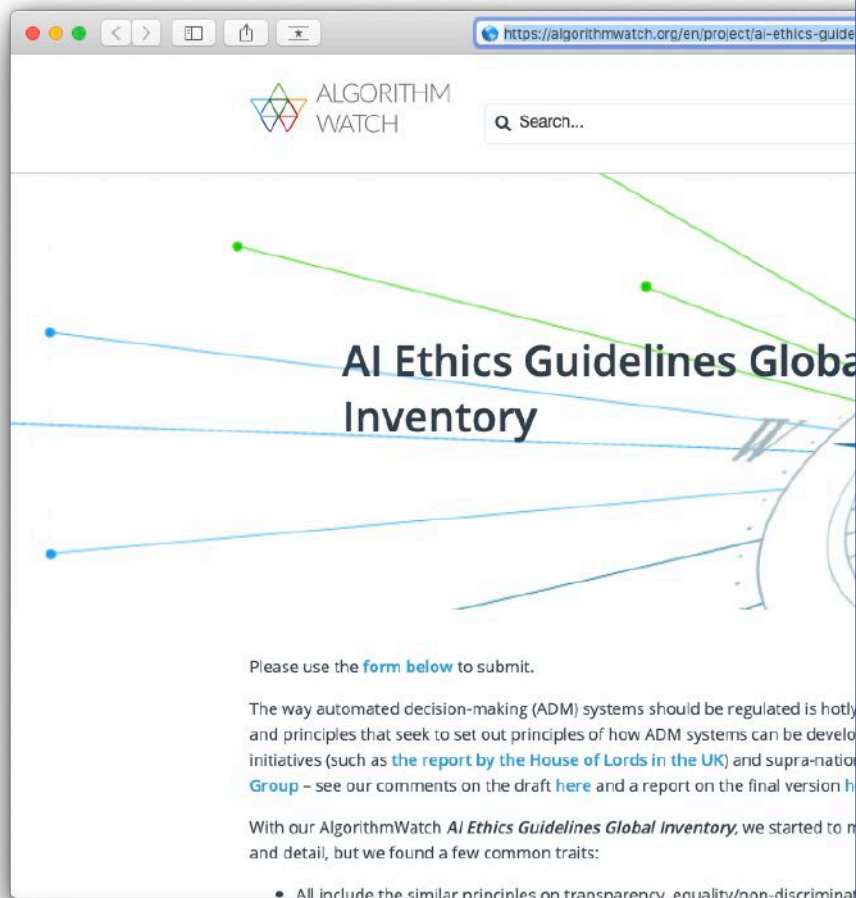
## Question #6

How do we identify  
analogies that are culturally  
unacceptable?

How do we deal with  
cultural differences?



## So how do we safeguard against these threats?



The way automated decision-making (ADM) systems should be regulated is hotly disputed. Recent months have seen a flurry of frameworks and principles that seek to set out principles of how ADM systems can be developed and implemented ethically. There are governmental initiatives (such as [the report by the House of Lords in the UK](#)) and supra-national efforts ([such as the EU commission's High Level Expert Group](#) – see our comments on the draft [here](#) and a report on the final version [here](#)). The private and civil sectors have also not been idle.

With our AlgorithmWatch **AI Ethics Guidelines Global Inventory**, we started to map the landscape of these frameworks. They vary in content and detail, but we found a few common traits:

- All include the similar principles on transparency, equality/non-discrimination, accountability and safety. Some add additional principles, such as the demand for AI be socially beneficial and protect human rights.
- Most frameworks are developed by coalitions, or institutions such as universities that then invite companies and individuals to sign up to these.
- Only a few companies have developed their own frameworks.
- Almost all examples are voluntary commitments. There are only three or four examples that indicate an oversight or enforcement mechanism.
- Apart from around 10 documents, all were published in 2018 or 2019 (some did not have a date).
- Overwhelmingly, the declarations take the form of statements, e.g. “we will ensure our data sets are not biased”. Few include recommendations or examples of how to operationalise the principles.

Our overview is certainly not complete; it is supposed to be a starting point. We assume there exist many more such guidelines that we are not aware of – due to our lack of language skills, or simply because they have not been widely announced.



Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative



## So how do we safeguard against these threats?

COUNCIL OF EUROPE  
Avenue de l'Europe  
F-67075 Strasbourg Cedex  
Tel. +33 (0)3 88 41 20 00  
CONSEIL DE L'EUROPE www.coe.int

Liberté d'expression

Vous êtes ici : Freedom of Expression > Comités

### MSI-AUT Comité d'experts sur la dimension droits de l'Homme des traitements automatisés de données et différentes formes d'intelligence artificielle



« Toute personne a droit à la liberté d'expression »  
Art. 10 de la Convention européenne des droits de l'homme

COUNCIL OF EUROPE PORTAL

## Committee of Ministers

Related documents Languages File Formats

CM-Public

MINISTERS' DEPUTIES Recommendations **CM/Rec(2020)1** 8 April 2020

### Recommendation CM/Rec(2020)1 of the Committee of Ministers to member States on the human rights impacts of algorithmic systems

(Adopted by the Committee of Ministers on 8 April 2020 at the 1373<sup>rd</sup> meeting of the Ministers' Deputies)

#### Preamble

The Committee of Ministers, under the terms of Article 15.b of the Statute of the Council of Europe, Considering that member States of the Council of Europe have committed themselves to ensuring the rights and freedoms enshrined in the Convention for the Protection of Human Rights and Fundamental







## So how do we safeguard against these threats?

### EU AI Act

- proposed 2021, currently in discussion, pass into law 2024
- **Defines AI** (Article 3):  
“‘AI system’ means a machine-based system that is designed to operate with varying levels of autonomy and that may exhibit adaptiveness after deployment, and that, for explicit or implicit objectives, infers, from the input it receives, how to generate outputs such as predictions, content, recommendations, or decisions that can influence physical or virtual environments;”
- **Categorizes AI**: prohibited, High-risk, General Purpose AI, minimal risk (unregulated)
- Regulates rules for each of these types of AI
- **Fines up to 35M€ or 7% of turnover**





## So how do we safeguard against these threats? EU AI Act — Prohibited AI systems (Title II, Art. 5)

- deploying **subliminal, manipulative, or deceptive techniques** to distort behaviour and impair informed decision-making, causing significant harm.
- **exploiting vulnerabilities** related to age, disability, or socio-economic circumstances to distort behaviour, causing significant harm.
- **biometric categorisation systems** inferring sensitive attributes (race, political opinions, trade union membership, religious or philosophical beliefs, sex life, or sexual orientation), except labelling or filtering of lawfully acquired biometric datasets or when law enforcement categorises biometric data.
- **social scoring**, i.e., evaluating or classifying individuals or groups based on social behaviour or personal traits, causing detrimental or unfavourable treatment of those people.
- **assessing the risk of an individual committing criminal offenses** solely based on profiling or personality traits, except when used to augment human assessments based on objective, verifiable facts directly linked to criminal activity.
- **compiling facial recognition databases** by untargeted scraping of facial images from the internet or CCTV footage.
- **inferring emotions in workplaces or educational institutions**, except for medical or safety reasons.
- **‘real-time’ remote biometric identification (RBI) in publicly accessible spaces** for law enforcement, except when:
  - searching for missing persons, abduction victims, and people who have been human trafficked or sexually exploited;
  - preventing substantial and imminent threat to life, or foreseeable terrorist attack; or
  - identifying suspects in serious crimes (e.g., murder, rape, armed robbery, narcotic and illegal weapons trafficking, organised crime, and environmental crime, etc.).




## So how do we safeguard against these threats? EU AI Act — High risk AI systems (Title III)


- Non-banned biometrics
- Critical Infrastructure
- Education and vocational training (admission, assignment, evaluation, assessment, monitoring)
- Employment, workers management and access to self-employment
  - recruitment or selection of natural persons, ... filter job applications, and to evaluate candidates;
  - make decisions affecting terms of work-related relationships, the promotion or termination ...
- Access to and enjoyment of essential private services and essential public services and benefits (public services, credit, fraud detection, risk assessment and pricing, emergency call triaging etc.)
- Law enforcement
- Migration, asylum and border control
- administration of justice

### High risk AI providers must:

- Establish a **risk management system** ...;
- Conduct **data governance**, ensuring that training, validation and testing datasets are relevant, sufficiently representative and, to the best extent possible, free of errors and complete according to the intended purpose.
- Draw up **technical documentation** to demonstrate compliance ...
- Design their high risk AI system for **record-keeping** ... for identifying national level risks and substantial modifications throughout the system's lifecycle.
- Provide **instructions for use** to downstream deployers to enable the latter's compliance.
- Design their high risk AI system to allow deployers to implement **human oversight**.
- ... appropriate levels of **accuracy, robustness, and cybersecurity**.
- ... a **quality management system** to ensure compliance.







## So how do we safeguard against these threats? EU AI Act — General Purpose AI Systems

- **GPAI model** means an AI model, including when trained with a large amount of data using self-supervision at scale, that displays significant generality and is capable to competently perform a wide range of distinct tasks regardless of the way the model is placed on the market and that can be integrated into a variety of downstream systems or applications. This does not cover AI models that are used before release on the market for research, development and prototyping activities.
- **All providers of GPAI models must:**
  - Draw up **technical documentation**, including training and testing process and evaluation results.
  - Draw up **information and documentation to supply to downstream providers** that intend to integrate the GPAI model into their own AI system in order that the latter understands capabilities and limitations and is enabled to comply.
  - Establish a policy to **respect the Copyright Directive**.
  - Publish a **sufficiently detailed summary about the content** used for training the GPAI model.
- **Free and open licence GPAI models** ... only have to comply with the latter two obligations above...
- **GPAI models present systemic risks when the cumulative amount of compute used for its training is greater than  $10^{25}$  floating point operations (FLOPs)**. Providers must notify the Commission if their model meets this criterion within 2 weeks.  
These must also:
  - Perform **model evaluations**, including conducting and documenting **adversarial testing** to identify and mitigate systemic risk.
  - **Assess and mitigate possible systemic risks**, including their sources.
  - **Track, document and report serious incidents** ...
  - Ensure an adequate level of **cybersecurity protection**.



Universität  
Zürich<sup>UZH</sup>

Digital Society Initiative



## Aktuell aus der UZH Forschung: Ein Rechtsrahmen für Künstliche Intelligenz

- Absehbar ist immerhin, dass allfällige Vorgaben des Europarates den Mitgliedstaaten viel Freiraum bei der Ausgestaltung ihrer nationalen Lösungen lassen werden.
- **Die Schweiz sollte diesen Freiraum nutzen, um einen eigenen Ansatz zu entwickeln.**



University of  
Zurich<sup>UZH</sup>

Digital Society Initiative

Positionspapier

## Ein Rechtsrahmen für Künstliche Intelligenz



Die grossen technischen Fortschritte im Bereich der **Künstlichen Intelligenz (KI)** und der Einsatz dieser Technologien in einer Vielzahl von Bereichen werfen grundlegende Fragen zu den Auswirkungen auf Individuen und die Gesellschaft auf. Der Begriff der Künstlichen Intelligenz weckt bisweilen irreführende Assoziationen und diffuse Ängste. Aus technischer Perspektive handelt es sich um einen etablierten Sammelbegriff, der **eine Reihe von Technologien** umfasst, die automatisierte Entscheidungen fällen, Empfehlungen machen, Schlussfolgerungen ziehen oder Vorhersagen treffen. Dazu gehören wissensbasierte Systeme und statistische

Florent Thouvenin, Markus Christen, Abraham Bernstein, Nadja Braun Binder, Thomas Burri, Karsten Donnay, Lena Jäger, Mariela Jaffé, Michael Krauthammer, Melinda Lohmann, Anna Mätzener, Sophie Mützel, Liliane Obrecht, Nicole Ritter, Matthias Spielkamp, Stephanie Volz

Dieses Positionspapier wurde im Rahmen eines Workshops erarbeitet, der vom 26. – 28. August 2021 in Balsthal durchgeführt und vom Strategy Lab der Digital Society Initiative (DSI) der Universität Zürich finanziert wurde. Neben den Autor\*innen dieses Papiers haben auch drei Vertreter\*innen der Bundesverwaltung an die



## Regelungsziele & Regelungsansatz

**möglichst viel Raum für die  
Entwicklung und Verwendung** von  
algorithmischen Systemen

durch die Verwendung von  
algorithmischen Systemen **dürfen  
betroffenen Personen und der  
Gesellschaft als Ganzes keine  
Nachteile** entstehen

- Kein generelles «KI-Gesetz» oder ein «Algorithmen-Gesetz». Angezeigt ist vielmehr eine **Kombination von allgemeinen und sektorspezifischen Normen**.
- **Punktuelle Anpassung bestehender Gesetze**.
- Allerdings dürfte es in nicht wenigen Fällen erforderlich sein, **die Auslegung und Anwendung bestehender Normen anzupassen**.
- Angesichts der Vielzahl der Erscheinungsformen algorithmischer Systeme ist grundsätzlich ein **technologieneutraler Ansatz** zu wählen.





## Regelungsbedarf

### Erkennbarkeit und Nachvollziehbarkeit

- Kennzeichnungspflicht
- Nachvollziehbarkeit
- Für Öffentlichkeit erkennbar (z.B. Register)

### Diskriminierung

- Keine Ungleichbehandlung aufgrund geschützter Merkmale
- Evtl. unabhängig von Entscheidungsmethode regeln
- Beweislastumkehr prüfen

### Manipulation

- Schutz demokratischer Willensbildung & Informations-/Meinungsfreiheit
- Schutz individueller Entscheidungsfreiheit und des Wettbewerbs
- Rückgängigmachung von Entscheidungen bei Manipulationen prüfen

### Haftung

- Verschuldensunabhängige Betreiberhaftung prüfen
- Haftung der Hersteller\*innen
- Algorithmischen Systeme als Produkte anerkennen

### Sicherheit

- Muss gängigen Sicherheitsstandards genügen
- Muss Datenschutz genügen
- IT-Sicherheitsgesetz prüfen

### Zulassungsverfahren

### Verbot oder Moratorium prüfen



## Regelungsbedarf

### Erkennbarkeit und Nachvollziehbarkeit

- Kennzeichnungspflicht
- Nachvollziehbarkeit
- Für Öffentlichkeit erkennbar (z.B. Register)

### Diskriminierung

- Keine Ungleichbehandlung aufgrund geschützter Merkmale
- Evtl. unabhängig von Entscheidungsmethode regeln
- Beweislastumkehr prüfen

### Zulassungsverfahren

### Manipulation

- Schutz demokratischer Willensbildung & Informations-/Meinungsfreiheit
- Schutz individueller Entscheidungsfreiheit und des Wettbewerbs

### Haftung

### Sicherheit

## Die Schweiz sollte

- zeitnah mit der **Erarbeitung von Normen** beginnen
- dafür eine **breit aufgestellte, interdisziplinär zusammengesetzte Expert\*innenkommission** berufen
- **Forschungsbedarf** erkennen und unterstützen




## Examples for Industry (Self-)Regulation



The four promises to customers in Zurich's data pledge are to:

- Keep their data safe
- Never sell their personal data
- Not share their personal data without being transparent about it
- Put their data to work so Zurich can better protect them, and so they can get the most out of life.

<https://www.zurich.com/en/media/news-releases/2019/2019-0903-01>



<https://digitaltrust-label.swiss/>



## Question #7

What kind of procedures does your institution plan to put in place AI regulation?

# Reflection

The core question here is  
neither what is  
nor what could be  
but what should be.



# Concluding Thought I

AI has huge potential!

Many AI challenges are not technical but organizational!




# Substitution of Human Work




Malone & Rockart, 1995


# Substitution of Human Work



Malone & Rockart, 1995



# Substitution of Human Work



Brynjolfsson et al '23 about *customer support agents*:

- **14% productivity increases** (issues resolved / hour)
- **34% improvement for novice & low-skilled workers**
- **durable learning**
- but with **minimal impact on experienced and highly skilled workers.**

Eloundou, et al. 2023:

- **science and critical thinking skills** are strongly negatively associated with exposure .. less likely to be impacted by current LLMs.
- Conversely, **programming and writing skills** show a strong positive association with exposure ...

Peng et al, 2023 (experimental study):


- **less experienced programmers benefit more**

Ziegler et al, 2024 (professional developers):

- Copilot **positively impacts productivity** (task time, quality, cognitive load, enjoyment) regardless of skill level
- Copilot **provides inspiration**/starting point for future exploration



# Substitution of Human Work?




Malone & Rockart, 1995

Tomas Lawton, Francisco J Ibarrola, Dan Ventura, and Kazjon Grace. 2023. Drawing with Reframer: Emergence and Control in Co-Creative AI. In *Proceedings of the 28th International Conference on Intelligent User Interfaces (IUI '23)*. Association for Computing Machinery, New York, NY, USA, 264–277. <https://doi.org/10.1145/3581641.3584095>

# Substitution of Human Work?


## Effect of GPT-4 use on a group of consultants

Source: Dell'Acqua et al., 2023 | Chart: 2024 AI Index report



## Effect of GPT-4 use on legal analysis by task

Source: Choi et al., 2023 | Chart: 2024 AI Index report



Human-AI

Capabilities


Dell'Acqua, Fabrizio, Edward McFowland III, Ethan Mollick, Hila Lifshitz-Assaf, Katherine C. Kellogg, Saran Rajendran, Lisa Kraye, François Candelon, and Karim R. Lakhani. "Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality." Harvard Business School Working Paper, No. 24-013, September 2023

Choi, Jonathan H. and Monahan, Amy and Schwarcz, Daniel, Lawyering in the Age of Artificial Intelligence (November 7, 2023). Minnesota Law Review, Forthcoming, Minnesota Legal Studies Research Paper No. 23-31, Available at SSRN: <https://ssrn.com/abstract=4626276> or

# Substitution of Human Work?

## Effects on job performance of receiving different types of AI advice

Source: Dell'Acqua, 2023 | Chart: 2024 AI Index report



Human-  
AI

Good AI: 85% accuracy  
Bad AI: 75% accuracy

Dell'Acqua, Fabrizio. Falling asleep at the wheel: Human/AI Collaboration in a Field Experiment on HR Recruiters. Working paper, 2022.



# Concluding Thought II

AI has huge potential!

How will you use it?

Substitutive, augmentative, or  
transformative?

# Vorlesungstermine: Wie geht es weiter?

| Datum                                        | Thema des Präsenzunterrichtes                                   | Videos / Selbstlernmodule                                                                              | Dozent:in  | Freischaltung<br>Übungen | Abgabe<br>Übungen |
|----------------------------------------------|-----------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|------------|--------------------------|-------------------|
| 18.9.                                        | Einführung / Motivation                                         | Filme Studium Digitale (1. Einführung)                                                                 | AB, IG, SV | Übung 1                  |                   |
| <b>Technische Grundlagen</b>                 |                                                                 |                                                                                                        |            |                          |                   |
| 25.9.                                        | Programmierung (CT nur wenn genügend Zeit)                      | Filme Studium Digitale (2. Computational Thinking, 3. Programmierung)                                  | IG         | Übung 2                  | Übung 1           |
| 2.10                                         | Digitale Daten                                                  | Filme Studium Digitale (4. Digitale Daten, 5. Datenvisualisierung, 6. Datenmanagement)                 | IG         |                          |                   |
| <b>Informationssysteme in Organisationen</b> |                                                                 |                                                                                                        |            |                          |                   |
| 9.10.                                        | Arten von IS - Einsatzgebiete, Wertschöpfungen, Klassifizierung | Arten von IS - Einsatzgebiete, Wertschöpfungen, Klassifizierung (7.1, 7.2, 7.3)                        | AB         |                          |                   |
| 16.10.                                       | ---                                                             |                                                                                                        |            |                          |                   |
| 23.10.                                       | Wert von IS und Informationen                                   | Wert von IS I & II (7.4, 7.5, 7.6, Skript: Der Wert von Information)                                   | AB         | Übung 3                  | Übung 2           |
| <b>Digitale Güter</b>                        |                                                                 |                                                                                                        |            |                          |                   |
| 30.10.                                       | Datenrecht                                                      | Filme Studium Digitale (9. Datenrecht)                                                                 | SV         |                          |                   |
| 6.11.                                        | Datenschutzrecht                                                | Filme Studium Digitale (10. Datenschutzrecht)                                                          | SV         | Übung 4                  | Übung 3           |
| <b>Recht und Informationssysteme</b>         |                                                                 |                                                                                                        |            |                          |                   |
| 13.11.                                       | Digitale Güter – Teil I                                         | Eigenschaften Digitaler Güter (8.1, 8.2), Massnahmen gegen Markverzerrungen (8.3), WS-Einleitung (8.4) |            |                          |                   |
| 20.11.                                       | Digitale Güter – Teil II                                        | WS-Preisdifferenzierung (8.5), WS-Produktdifferenzierung (8.6), WS-Bundling (8.7, 8.8)                 | AB         | Übung 5                  | Übung 4           |
| <b>Ausblick und Abschluss</b>                |                                                                 |                                                                                                        |            |                          |                   |
| 27.11.                                       | Künstliche Intelligenz                                          | Filme Studium Digitale (11. KI & ML)                                                                   | AB         |                          |                   |
| 4.12.                                        | ---                                                             |                                                                                                        |            |                          | Übung 5           |
| 11.12.                                       | <i>Repetitorium und Diskussion</i>                              |                                                                                                        | AB, IG, SV |                          |                   |
| 15.12.                                       | <i>Prüfungswoche</i>                                            |                                                                                                        | ---        |                          |                   |
| <b>18.12. Prüfung</b>                        |                                                                 |                                                                                                        |            |                          |                   |

AB = Abraham Bernstein, IG = Ivan Giangreco, SV = Stephanie Volz



# COMPUTERS *and the* ECONOMY



Bis zur nächsten  
Vorlesung ...